

Matriz de Optimizacion de Costos IA

Sistema de Triage de Tickets de Soporte — justificacion de modelo por tarea

Tarea	Modelo usado	Costo aprox. (input/output por 1M tokens)	Por que este modelo
Clasificacion de tickets (categoria + urgencia + resumen)	GPT-4o-mini	\$0.15 / \$0.60	Tarea simple y estructurada (clasificacion + resumen corto). No requiere razonamiento profundo ni lectura de documentos extensos: un modelo mini optimiza costo sin perder precision.
Lectura de tickets muy largos o con contexto adjunto (ej. logs)	Claude (Sonnet)	\$3.00 / \$15.00	Mejor comprension de contexto extenso y instrucciones complejas. Se reserva para casos donde el ticket incluye adjuntos largos o requiere razonamiento multi-paso (no es el camino por defecto del flujo).
Procesamiento masivo / reprocesamiento historico	OpenAI Batch API	50% del costo estandar (\$0.075 / \$0.30 con GPT-4o-mini)	Para reclasificar tickets historicos o correr pruebas de carga sin necesidad de respuesta en tiempo real, el Batch API reduce el costo a la mitad a cambio de un SLA de hasta 24hs.

Estimacion de ahorro

Suponiendo un volumen de **500 tickets/mes**, con un promedio de ~250 tokens de entrada (mensaje del ticket + prompt de sistema) y ~80 tokens de salida (JSON de clasificacion) por ticket:

Escenario	Modelo	Costo estimado / mes	Ahorro vs. GPT-4o
Usar GPT-4o (modelo full) para todo	GPT-4o	~\$2.19 USD	—
Usar GPT-4o-mini (solucion implementada)	GPT-4o-mini	~\$0.14 USD	~94% menos
Reprocesamiento historico via Batch API	GPT-4o-mini (Batch)	~\$0.07 USD	~97% menos

Otras medidas de optimizacion aplicadas

- **Max Tokens limitado** en el nodo de IA para evitar respuestas largas innecesarias (el output es un JSON breve de 4 campos).
- **Output Format = JSON** forzado en el modelo: evita reintentos por respuestas mal formateadas que consumirian tokens extra.
- **Prompt de sistema fijo y corto**, sin ejemplos few-shot extensos, ya que la tarea de clasificacion no los requiere para mantener precision aceptable.
- **Trigger por Webhook** (no polling): el flujo solo consume recursos cuando llega un ticket real, sin ejecuciones programadas innecesarias.