

Matriz de Optimizacion de Costos IA

Sistema de Triage de Tickets de Soporte — justificacion de modelo por tarea

Tarea	Modelo usado	Costo aprox. (input/output por 1M tokens)	Por que este modelo
Clasificacion de tickets (categoria + urgencia + resumen + area)	Claude Haiku 4.5	\$1.00 / \$5.00	Tarea simple y estructurada (clasificacion + resumen corto). No requiere razonamiento profundo: el modelo mas rapido y economico de la familia Claude entrega precision suficiente para este caso de uso.
Lectura de tickets muy largos o con adjuntos extensos (ej. logs, capturas)	Claude Sonnet 5	\$3.00 / \$15.00	Mejor comprension de contexto extenso y capacidad de analizar imagenes/documentos adjuntos. Se reserva para casos donde el ticket incluye material largo o complejo, no es el camino por defecto del flujo.
Procesamiento masivo / reprocesamiento historico no urgente	Anthropic Batch API	50% del costo estandar (\$0.50 / \$2.50 con Haiku)	Para reclasificar tickets historicos o correr pruebas de carga sin necesidad de respuesta en tiempo real, el Batch API reduce el costo a la mitad a cambio de un SLA de hasta 24hs.

Estimacion de ahorro

Suponiendo un volumen de **500 tickets/mes**, con un promedio de ~260 tokens de entrada (mensaje del ticket + prompt de sistema) y ~90 tokens de salida (JSON de clasificacion) por ticket:

Escenario	Modelo	Costo estimado / mes	Ahorro vs. Opus
Usar Claude Opus (modelo top) para todo	Claude Opus	~\$8.10 USD	—
Usar Claude Haiku 4.5 (solucion implementada)	Claude Haiku 4.5	~\$0.17 USD	~98% menos
Reprocesamiento historico via Batch API	Claude Haiku (Batch)	~\$0.09 USD	~99% menos

Otras medidas de optimizacion aplicadas

- **Max Tokens limitado** (300) en el nodo de IA para evitar respuestas largas innecesarias (el output es un JSON breve de 4 campos).
- **Temperatura en 0**: al ser una tarea de clasificacion determinista, no se paga el costo de variabilidad ni se arriesgan reintentos por respuestas inconsistentes.
- **Prompt de sistema fijo y corto**, sin ejemplos few-shot extensos, ya que la tarea de clasificacion no los requiere para mantener precision aceptable.
- **Trigger por Webhook** (no polling): el flujo solo consume recursos cuando llega un ticket real, sin ejecuciones programadas innecesarias.
- **Manejo de errores sin reintentos automaticos infinitos**: un fallo de la API de IA se registra y notifica una sola vez, evitando bucles de reintento que multipliquen el costo.